

Universidad Nacional Autónoma de México

FACULTAD DE CIENCIAS

Ciencias de la Computación



Reconocimiento de Patrones y Aprendizaje Automatizado

Proyecto Final

Predicción de Precios en el Mercado Accionario mediante
Support Vector Regression

Lorena González Téllez

No. de cuenta: 321288952

29 de mayo de 2026

Índice

1. Introducción	3
2. Regresión de Vectores de Soporte SVR	4
2.1. La base: Máquinas de Vectores de Soporte (SVM)	4
2.2. Los Fundamentos de SVR	5
2.3. El Problema Dual y los Vectores de Soporte	6
2.4. Funciones Kernel	7
3. Indicadores Técnicos como Variables Predictoras	8
3.1. Media Móvil Simple (SMA)	8
3.2. Media Móvil Ponderada (WMA)	8
3.3. Índice de Fuerza Relativa (RSI)	9
3.4. Oscilador Acumulación/Distribución (ADO)	9
3.5. Rango Verdadero Promedio (ATR)	9
4. Métricas de Evaluación	11
4.1. MAPE — Error Porcentual Absoluto Medio	11
4.2. RMSE — Raíz del Error Cuadrático Medio	11
5. Regresión Ridge	12
5.1. Ridge Lineal	12
5.2. Kernel en Regresión Ridge	12
6. Caminata Aleatoria	13
7. Implementación	14
7.1. Datos Históricos del Mercado Accionario	14
7.2. Volatilidad de las acciones seleccionadas	14
7.3. Preprocesamiento del conjunto de datos	15
7.4. Normalización	15
7.5. Conjunto de entrenamiento y de prueba	16
7.6. Modelos Evaluados	16
8. Selección de Hiperparámetros con Validación Cruzada	18
8.1. Motivación	18
8.2. Validación cruzada temporal	18
8.3. Grillas de búsqueda	18

9. Resultados de los Modelos	20
9.1. Precisión Predictiva: RMSE y MAPE	20
9.2. Ranking Global de Modelos	21
9.3. Comportamiento por Acción	22
10. Impacto de la Validación Cruzada y Análisis de Complejidad	23
10.1. Efecto de la Validación Cruzada sobre el RMSE	23
10.2. Complejidad Estructural contra Desempeño Predictivo	24
10.3. Conclusión: Desempeño, Validación Cruzada y Complejidad	25
11. Estrategia de Ventana Deslizante	27
11.1. Motivación	27
11.2. Formulación Matemática	27
11.3. Decisiones de Implementación	27
11.4. Resultados de los Modelos con Ventana Deslizante	28
11.5. Análisis de Resultados	29
12. Conclusiones	31
12. Visualización de Gráficos	33

1. Introducción

La predicción de precios en el mercado accionario representa uno de los problemas más estudiados y, al mismo tiempo, más difíciles del aprendizaje automatizado aplicado a las finanzas. Su relevancia práctica es directa: inversionistas, analistas y administradores de carteras toman decisiones de alto impacto económico con base en estimaciones sobre el comportamiento futuro de los activos.

Sin embargo, las series de tiempo financieras presentan características intrínsecas que las distinguen de otros dominios de predicción y que limitan la eficacia de los modelos tradicionales. En primer lugar, exhiben **no linealidad y no estacionariedad**: la relación entre la información de precios actual y el precio futuro no es fija. En segundo lugar, presentan **alta volatilidad y ruido estocástico**: los movimientos de corto plazo están dominados por componentes aleatorios que ningún modelo puede capturar sistemáticamente, lo que impone un techo natural a la precisión alcanzable. En tercer lugar, los precios tienen **memoria larga y dependencias no triviales**: las correlaciones entre observaciones distantes en el tiempo pueden ser estadísticamente significativas, pero su estructura cambia de régimen de manera abrupta, dificultando su modelado con ventanas de observación fijas.

Ante este panorama, la evidencia empírica sugiere que los mercados reales presentan ineficiencias locales y temporales que los modelos de aprendizaje automatizado pueden explotar parcialmente, especialmente cuando se incorporan indicadores técnicos que capturan la dinámica reciente de los precios.

En este contexto, el presente proyecto propone la evaluación del modelo de **Support Vector Regression** (SVR) para la predicción del precio de cierre diario de seis activos del mercado accionario estadounidense. La elección de SVR está motivada por dos propiedades que lo hacen conceptualmente adecuado para series financieras ruidosas: su función de pérdida ε -insensible, que ignora errores pequeños dentro de un tubo de tolerancia, y su principio de minimización del riesgo estructural, que penaliza la complejidad del modelo y favorece la generalización sobre datos no vistos. El desempeño del SVR se contrasta contra la Regresión Ridge y la Caminata Aleatoria como modelos de referencia, y se analiza el impacto de proyectar los datos a espacios de mayor dimensión mediante funciones kernel lineal y de base radial (RBF), evaluando si esta transformación permite capturar relaciones no lineales entre los indicadores técnicos y el precio futuro.

2. Regresión de Vectores de Soporte SVR

2.1. La base: Máquinas de Vectores de Soporte (SVM)

Las Máquinas de Vectores de Soporte (SVM) son modelos de aprendizaje supervisado desarrollados por Vapnik (1995) para clasificación binaria. Veremos que SVR hereda directamente su estructura matemática: el problema de optimización, las variables de holgura y el parámetro de regularización C se trasladan sin modificación al caso de regresión.

Formulación de margen rígido

Dado un conjunto de entrenamiento $\{(\mathbf{x}_k, y_k)\}_{k=1}^N$, con $\mathbf{x}_k \in \mathbb{R}^n$ e $y_k \in \{-1, +1\}$, el hiperplano separador en el espacio de características se define como:

$$\mathbf{w}^T \phi(\mathbf{x}) + b = 0 \quad (1)$$

donde $\mathbf{w}$ es el vector normal al hiperplano, b el término de sesgo y $\phi(\mathbf{x})$ una transformación que proyecta los datos a un espacio de mayor dimensión. Para que cada punto quede correctamente clasificado, se requiere:

$$y_k [\mathbf{w}^T \phi(\mathbf{x}_k) + b] \geq 1, \quad k = 1, \dots, N \quad (2)$$

El margen geométrico entre ambas clases es $\frac{2}{\|\mathbf{w}\|}$, por lo que maximizarlo equivale a minimizar $\frac{1}{2}\|\mathbf{w}\|^2$. Esto conduce al problema de optimización de margen rígido:

$$\min_{\mathbf{w}, b} \quad \frac{1}{2}\|\mathbf{w}\|^2 \quad \text{sujeto a} \quad y_k [\mathbf{w}^T \phi(\mathbf{x}_k) + b] \geq 1, \quad k = 1, \dots, N \quad (3)$$

Formulación de margen suave

Debido a que los datos no siempre son linealmente separables, se introducen variables de holgura $\xi_k \geq 0$ que permiten que ciertos puntos violen la restricción de margen en una magnitud ξ_k . El problema se reformula como:

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2}\|\mathbf{w}\|^2 + C \sum_{k=1}^N \xi_k \\ \text{sujeto a} \quad & y_k [\mathbf{w}^T \phi(\mathbf{x}_k) + b] \geq 1 - \xi_k, \\ & \xi_k \geq 0, \quad k = 1, \dots, N \end{aligned} \quad (4)$$

El hiperparámetro $C > 0$ regula el equilibrio entre dos objetivos contrapuestos: un C grande penaliza severamente las violaciones del margen, mientras que un C pequeño

tolera más violaciones a cambio de un margen más amplio y una mejor capacidad de generalización.

2.2. Los Fundamentos de SVR

Aunque SVM fue concebido para la clasificación discreta, sus principios matemáticos fueron extendidos para predecir valores continuos $y \in \mathbb{R}$, dando origen a la Regresión de Vectores de Soporte (SVR). A diferencia de la regresión lineal tradicional, que busca minimizar el error cuadrático medio sobre todos los puntos de entrenamiento, SVR busca una función de regresión de la forma:

$$f(\mathbf{x}, \mathbf{w}) = \mathbf{w}^T \mathbf{x} + b \quad (5)$$

Para ello, SVR introduce la **función de pérdida ε -insensible**, que ignora los errores de predicción dentro de un radio de tolerancia ε alrededor del valor real y penaliza únicamente los que exceden ese umbral:

$$|y - f(\mathbf{x}, \mathbf{w})|_\varepsilon = \begin{cases} 0, & \text{si } |y - f(\mathbf{x}, \mathbf{w})| \leq \varepsilon \\ |y - f(\mathbf{x}, \mathbf{w})| - \varepsilon, & \text{en otro caso} \end{cases} \quad (6)$$

Combinando (5) con (6), la función objetivo a minimizar es:

$$R(\mathbf{w}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N |y_i - f(\mathbf{x}_i)|_\varepsilon \quad (7)$$

Esta expresión contiene dos términos con roles complementarios:

Término	Significado
$\frac{1}{2} \ \mathbf{w}\ ^2$	Controla la complejidad del modelo: una norma grande de $\mathbf{w}$ produce funciones con alta variación que tienden al sobreajuste.
$C \sum_{i=1}^N y_i - f(\mathbf{x}_i) _\varepsilon$	Penaliza los errores que superan el umbral ε . El parámetro $C > 0$ regula cuánto peso se asigna a estas violaciones frente a la regularización.

Dado que el valor absoluto en (7) no es diferenciable en todos los puntos, se reformula el problema introduciendo dos variables de holgura por observación: $\zeta_i \geq 0$ para los errores por encima del tubo y $\zeta_i^* \geq 0$ para los errores por debajo. El problema de

optimización primal de SVR queda entonces como:

$$\min_{\mathbf{w}, b, \zeta, \zeta^*} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N (\zeta_i + \zeta_i^*) \quad (8)$$

sujeto a:

$$f(\mathbf{x}_i) - y_i \leq \varepsilon + \zeta_i \quad (9)$$

$$y_i - f(\mathbf{x}_i) \leq \varepsilon + \zeta_i^* \quad (10)$$

$$\zeta_i, \zeta_i^* \geq 0, \quad i = 1, \dots, N \quad (11)$$

Las restricciones (9) y (10) definen el tubo de tolerancia ε : un punto solo activa una variable de holgura cuando su error de predicción supera el umbral. El parámetro C actúa, al igual que en SVM, como factor de compensación entre la planitud del modelo y el grado en que se toleran desviaciones fuera del tubo.

2.3. El Problema Dual y los Vectores de Soporte

Para resolver el problema de optimización de SVR, se aplica el método de multiplicadores de Lagrange, introduciendo variables duales $\alpha_i \geq 0$ y $\alpha_i^* \geq 0$ para las restricciones del tubo superior e inferior, respectivamente. Al minimizar el Lagrangiano respecto a las variables primales $(\mathbf{w}, b, \zeta_i, \zeta_i^*)$ e igualar sus derivadas parciales a cero, se obtiene que el vector de pesos admite la representación:

$$\mathbf{w} = \sum_{i=1}^N (\alpha_i - \alpha_i^*) \mathbf{x}_i \quad (12)$$

Este resultado, determina qué puntos de entrenamiento contribuyen efectivamente a $\mathbf{w}$:

- **Puntos dentro del tubo** ($|y_i - f(\mathbf{x}_i)| < \varepsilon$): sus restricciones se satisfacen con desigualdad estricta y $\alpha_i = \alpha_i^* = 0$. Estos puntos son descartados del modelo.
- **Puntos en la frontera o fuera del tubo** ($|y_i - f(\mathbf{x}_i)| \geq \varepsilon$): sus restricciones son activas y sus multiplicadores son estrictamente positivos. Estos puntos son los únicos que determinan $\mathbf{w}$ y se denominan **vectores de soporte**.

Sustituyendo (12) en la función de predicción e introduciendo el truco del kernel $K(\mathbf{x}_i, \mathbf{x}) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x})$, la ecuación de predicción toma la forma:

$$f(\mathbf{x}) = \sum_{i=1}^N (\alpha_i - \alpha_i^*) K(\mathbf{x}_i, \mathbf{x}) + b \quad (13)$$

La sumatoria se reduce en la práctica a los vectores de soporte. Esta propiedad otorga al SVR dos ventajas concretas: eficiencia computacional, al evaluar únicamente un subconjunto de los datos de entrenamiento, y robustez ante el ruido estocástico, al ignorar activamente las observaciones que caen dentro del margen de tolerancia ε .

2.4. Funciones Kernel

En problemas complejos como la predicción financiera, las relaciones entre las variables independientes y la variable objetivo rara vez son estrictamente lineales. La introducción de las funciones Kernel sustituye el producto interno estándar $x_i^T x_j$ por una función Kernel $K(x_i, x_j) \equiv \phi(x_i)^T \phi(x_j)$ que mapea implícitamente los datos hacia un espacio de características de dimensión superior, donde es posible trazar una regresión lineal sin necesidad de calcular explícitamente las transformaciones dimensionales.

Las funciones Kernel más empleadas en la literatura son:

- **Kernel Lineal:** Representa el mapeo de identidad y se define como $K(x_i, x_j) = x_i^T x_j$. Es computacionalmente eficiente y es ideal cuando la relación subyacente es predominantemente lineal o cuando la dimensión de las características es muy alta, reduciendo el riesgo de sobreajuste.
- **Kernel Polinomial:** Se define como $K(x_i, x_j) = (x_i^T x_j + 1)^d$, donde el hiperparámetro d especifica el grado del polinomio. Permite modelar interacciones no lineales proyectando los datos a un espacio poli-dimensional.
- **Kernel de Función de Base Radial RBF:** Es el Kernel no lineal más versátil y se define como $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$ para $\gamma > 0$. El parámetro γ define inversamente el radio de influencia de cada vector de soporte individual: valores altos de γ generan un modelo capaz de ajustarse a oscilaciones complejas, pero con un alto riesgo de memorizar el ruido temporal del mercado.

La optimización correcta de los parámetros del Kernel (como γ o d), en combinación con el factor de regularización C y el margen ϵ , es crítica. Un modelo bien calibrado es capaz de aislar el ruido estocástico de los mercados financieros y generalizar tendencias.

3. Indicadores Técnicos como Variables Predictoras

Siguiendo a Henrique et al. (2018), se utilizan cinco indicadores técnicos calculados con período $P = 10$ días como variables predictoras. Cada indicador se calcula sobre los precios históricos diarios y captura un aspecto diferente del comportamiento de la acción.

A continuación se considera:

- P : periodo de tiempo (días)
- Cl : precio de cierre
- Hi : precio más alto del día
- Lo : precio más bajo del día
- Up : número de alzas de precio
- Dw : número de bajas de precio

3.1. Media Móvil Simple (SMA)

$$SMA_t = \frac{1}{P} \sum_{i=1}^P Cl_{t-i+1} \quad (14)$$

Promedio aritmético del precio de cierre de los últimos P días. Suaviza las fluctuaciones de corto plazo y muestra la tendencia general. Si el precio está por encima de la SMA, se considera tendencia alcista; por debajo, bajista.

3.2. Media Móvil Ponderada (WMA)

$$WMA_t = \frac{P \cdot Cl_t + (P-1) \cdot Cl_{t-1} + \dots + 1 \cdot Cl_{t-P+1}}{P + (P-1) + \dots + 1} = \frac{\sum_{j=1}^P j \cdot Cl_{t-P+j}}{\sum_{j=1}^P j} \quad (15)$$

Sigue la lógica de SMA pero asignando pesos linealmente crecientes a los precios más recientes. El día más reciente recibe peso P y el más antiguo peso 1. Es más reactiva que la SMA a cambios recientes en el precio.

3.3. Índice de Fuerza Relativa (RSI)

$$RSI_t = 100 - \frac{100}{1 + \frac{\bar{U}_P}{\bar{D}_P}} \quad (16)$$

donde $\bar{U}_P$ es el promedio de subidas y $\bar{D}_P$ el promedio de bajadas en los últimos P días.

Este es un oscilador que varía entre 0 y 100, donde:

- $RSI > 70$: mercado *sobrecomprado* (posible corrección bajista)
- $RSI < 30$: mercado *sobrevendido* (posible rebote alcista)
- $RSI \approx 50$: mercado en equilibrio

3.4. Oscilador Acumulación/Distribución (ADO)

$$ADO_t = \frac{Hi_t - Cl_{t-1}}{Hi_t - Lo_t} \quad (17)$$

donde Hi_t y Lo_t son el máximo y mínimo del día t .

Este indicador mide la fortaleza de la tendencia comparando el máximo del día actual con el cierre del día anterior. Un ADO alto indica que el precio subió con fuerza respecto a ayer; uno bajo, que bajó con fuerza.

3.5. Rango Verdadero Promedio (ATR)

En el análisis técnico, la volatilidad suele medirse de forma simplificada como la diferencia entre el precio máximo y el mínimo de una sesión ($Hi_t - Lo_t$). Sin embargo, esta medida ignora los huecos que ocurren entre el cierre de un día y la apertura del siguiente.

El Rango Verdadero (TR) captura la volatilidad real incluyendo posibles huecos entre sesiones, se define como el máximo de tres posibles escenarios de movimiento de precios:

$$TR_t = \max(Hi_t - Lo_t, |Hi_t - Cl_{t-1}|, |Lo_t - Cl_{t-1}|) \quad (18)$$

- $Hi_t - Lo_t$: Representa la volatilidad dentro de la sesión actual (la distancia total recorrida entre el punto más alto y el más bajo).
- $|Hi_t - Cl_{t-1}|$: Captura la distancia entre el máximo de hoy y el cierre de ayer. Es fundamental cuando el mercado abre con un gap al alza.

- $|Lo_t - Cl_{t-1}|$: Captura la distancia entre el mínimo de hoy y el cierre de ayer. Es fundamental cuando el mercado abre con un gap a la baja.

Al seleccionar el valor máximo de estos tres, el TR garantiza que el indicador refleje la mayor distancia recorrida por el precio, sin importar si el movimiento fue continuo o si hubo saltos nocturnos.

El ATR es el promedio exponencial del TR con período P :

$$ATR_t = \frac{ATR_{t-1}(P - 1) + TR_t}{P} \quad (19)$$

Mide la *volatilidad* del precio. Un ATR alto indica movimientos grandes (mercado volátil); uno bajo indica movimientos pequeños (mercado estable). Es útil porque captura tanto la amplitud del día como los saltos entre sesiones.

4. Métricas de Evaluación

Para evaluar el desempeño de los modelos se utilizan las siguientes métricas. Para las siguientes fórmulas consideramos:

- T : número de muestras de prueba
- d : precio real de la muestra
- $\hat{d}$: valor estimado por el modelo

4.1. MAPE — Error Porcentual Absoluto Medio

$$\text{MAPE} = \frac{1}{T} \sum_{i=1}^T \left| \frac{d_i - \hat{d}_i}{d_i} \right| \quad (20)$$

MAPE expresa el error en términos relativos (porcentaje), lo que facilita la comparación de la precisión entre diferentes activos, independientemente de su valor nominal en el mercado. Un MAPE de 1 % significa que en promedio el modelo se equivoca en el 1 % del precio real.

Un MAPE bajo (cercano a 0) indica que las predicciones del modelo están muy cerca de los precios reales de cierre. Un MAPE alto sugiere que el modelo tiene dificultades para capturar la volatilidad o las tendencias no lineales de la acción.

4.2. RMSE — Raíz del Error Cuadrático Medio

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{i=1}^T (d_i - \hat{d}_i)^2} \quad (21)$$

RMSE mide el error promedio en las mismas unidades que el precio (dólares). Un RMSE de 3.5 significa que el modelo se equivoca en promedio \$3.50 por predicción, pero los errores grandes cuentan más.

Debido a que los errores se elevan al cuadrado antes de promediarse, el RMSE penaliza mucho más los fallos grandes que los pequeños. Esto es crucial en finanzas, donde una predicción muy alejada de la realidad puede implicar un riesgo mucho mayor.

5. Regresión Ridge

Para poder realizar una comparación de la eficiencia del modelo SVR utilizaremos la regresión Ridge como referencia.

5.1. Ridge Lineal

Ridge minimiza la suma de cuadrados con una penalización sobre los coeficientes:

$$\min_{\mathbf{w}} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \alpha \|\mathbf{w}\|^2 \quad (22)$$

A diferencia de la regresión lineal ordinaria, Ridge agrega el término $\alpha \|\mathbf{w}\|^2$ que penaliza coeficientes grandes, evitando sobreajuste cuando las variables predictoras están correlacionadas. El parámetro α controla la fuerza de la regularización.

La solución analítica de Ridge es:

$$\hat{\mathbf{w}} = (\mathbf{X}^T \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y} \quad (23)$$

5.2. Kernel en Regresión Ridge

Al aplicar el truco del kernel a Ridge, la función objetivo se convierte en:

$$\min_{\boldsymbol{\alpha}} \|\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}\|^2 + \alpha \boldsymbol{\alpha}^T \mathbf{K} \boldsymbol{\alpha} \quad (24)$$

donde $\mathbf{K}$ es la matriz de kernel con $K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$. Esto permite capturar relaciones no lineales entre los indicadores y el precio.

6. Caminata Aleatoria

Como punto de partida fundamental para validar la eficacia de los modelos de aprendizaje automatizado, se utiliza la Caminata Aleatoria como otro modelo de referencia. Este enfoque se fundamenta en la **Hipótesis de los Mercados Eficientes** (EMH, por sus siglas en inglés), la cual postula que los precios de los activos reflejan instantáneamente toda la información disponible. Bajo esta premisa, cualquier cambio futuro en el precio es resultado de información nueva e impredecible, lo que implica que los rendimientos se comportan como una variable aleatoria sin memoria.

Matemáticamente, el comportamiento del precio de cierre (Cl) en un mercado eficiente se define como:

$$Cl_t = Cl_{t-1} + r_t, \quad r_t \sim \mathcal{N}(0, \sigma^2) \quad (25)$$

Donde el término r_t representa el rendimiento en el tiempo t , el cual se asume como ruido blanco; es decir, sigue una distribución normal con media cero y una varianza constante σ^2 . Esta estructura implica que el mejor estimador para el precio de mañana es, simplemente, el precio observado el día de hoy:

$$\hat{Cl}_{t+1} = Cl_t \quad (26)$$

Si los modelos de Support Vector Regression (SVR) o Ridge no logran superar la precisión de la caminata aleatoria, se concluye que los indicadores técnicos utilizados como variables predictoras no aportan valor informativo adicional sobre el precio actual.

7. Implementación

La implementación práctica de los modelos presentados se realiza con ayuda de librerías de Python como `yfinance`, `pandas`, `numpy` y `sklearn`.

7.1. Datos Históricos del Mercado Accionario

Para la aplicación de los modelos de predicción mencionados hasta ahora se seleccionaron las siguientes emisoras del mercado accionario:

- Alphabet Inc (GOOGL)
- Broadcom (AVGO)
- Cisco Systems Inc (CSCO)
- Dell Tech (DELL)
- Hewlett Packard Enterprise Co (HPE)
- Micron Technology Inc (MU)

Se obtuvieron los datos de: precio de apertura del día, precio máximo alcanzado, precio mínimo alcanzado, precio de cierre del día y volumen negociado en número de acciones para cada día registrado desde el 1 de enero de 2020 hasta el 1 de mayo de 2026.

7.2. Volatilidad de las acciones seleccionadas

Con el fin de caracterizar el comportamiento de cada activo durante el período de estudio (2021–2026), se calcularon tres métricas de riesgo complementarias: la **volatilidad anualizada** (desviación estándar de los rendimientos diarios escalada por $\sqrt{252}$), el **coeficiente Beta** respecto al índice S&P 500 (sensibilidad del activo ante movimientos del mercado) y el **rango diario promedio** (promedio de $(Hi_t - Lo_t)/Cl_{t-1}$ como porcentaje). Los resultados se presentan en el Cuadro 1. La selección de este conjunto de acciones nos muestra variedad en su volatilidad, esto con el fin de poder evaluar los modelos con distintos comportamientos en el mercado accionario.

Cuadro 1: Métricas de volatilidad de las seis acciones seleccionadas para el período 2020 –2026, ordenadas de mayor a menor volatilidad anualizada.

Acción	Vol. Anualizada	Beta	Rango Diario
MU	50.25 %	1.803	3.73 %
DELL	46.02 %	1.426	3.16 %
AVGO	42.24 %	1.645	3.02 %
HPE	36.19 %	1.220	2.76 %
GOOGL	31.16 %	1.273	2.34 %
CSCO	23.33 %	0.837	1.78 %

7.3. Preprocesamiento del conjunto de datos

El preprocesamiento se divide en tres pasos críticos:

- Generación de la Variable Objetivo: El objetivo de la predicción es obtener el precio de cierre del día siguiente. Se realiza un desplazamiento negativo sobre el precio de cierre, de modo que cada fila de datos contenga los indicadores del día actual correlacionados con el precio de cierre del día siguiente (Cl_{t+1}).
- Cálculo de Indicadores: Se transforman los precios crudos en variables de análisis técnico utilizando una ventana de observación fija de $P = 10$ días. De modo que las variables predictoras son: SMA, WMA, RSI, ADO, ATR.
- Limpieza de Series: Debido a que el cálculo de indicadores móviles genera valores nulos (NaN) en los primeros P días y el desplazamiento de la variable objetivo deja la última fila sin etiqueta, se aplica una eliminación rigurosa de estas muestras incompletas para garantizar la integridad del entrenamiento.

7.4. Normalización

Antes de entrenar cualquier modelo se normalizan las cinco variables predictoras (los indicadores técnicos) al rango $[0, 1]$ mediante:

$$x'_i = \frac{x_i - \text{mín}(\mathbf{x})}{\text{máx}(\mathbf{x}) - \text{mín}(\mathbf{x})} \quad (27)$$

Nota: El normalizador (**MinMaxScaler**) se ajusta únicamente con los datos de entrenamiento y se aplica a los datos de prueba con los mismos parámetros. Si se ajusta con todo el conjunto de datos, se introduciría información del futuro en el entrenamiento, invalidando la evaluación.

7.5. Conjunto de entrenamiento y de prueba

Para N muestras:

$$\text{Entrenamiento} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{\lfloor 0,7N \rfloor}, \quad \text{Prueba} = \{(\mathbf{x}_i, y_i)\}_{i=\lfloor 0,7N \rfloor+1}^N \quad (28)$$

En las series de tiempo del mercado accionario no se deben mezclar datos futuros con datos pasados, por lo que los modelos serán entrenados con datos del pasado. La división del conjunto de datos se realiza tomando el 70 % de los datos (los más antiguos) para entrenamiento y el 30 % restantes (los más recientes) para prueba.

7.6. Modelos Evaluados

Para la fase experimental se configuraron cuatro arquitecturas predictivas basadas en máquinas de vectores de soporte y regresión lineal regularizada.

Ridge Lineal

Inicialmente se configura con un parámetro de regularización $\alpha = 1,0$, que pondera equitativamente el error cuadrático medio del ajuste y la norma L_2 de los pesos ($\|\mathbf{w}\|_2^2$). La complejidad estructural es constante e independiente del número de muestras de entrenamiento:

$$n_{\text{params}} = \underbrace{d}_{5 \text{ indicadores}} + \underbrace{1}_{\text{intercepto}} + \underbrace{1}_{\alpha} = 7$$

Ridge con Kernel RBF

Utiliza $\alpha = 1,0$ y $\gamma = 0,1$. A diferencia de la variante lineal, la complejidad del modelo Ridge con kernel depende directamente del conjunto de entrenamiento:

$$n_{\text{params}} = \underbrace{2}_{\{\alpha, \gamma\}} + \underbrace{N_{\text{train}}}_{\text{coeficientes duales}}$$

SVR Lineal

En principio, se define con una constante de penalización $C = 1,0$ y un radio de insensibilidad $\varepsilon = 0,1$. La complejidad de este modelo es proporcional al número de vectores de soporte (n_{SV}), los cuales representan las muestras críticas que definen el margen:

$$n_{\text{params}} = \underbrace{2}_{\{C, \varepsilon\}} + \underbrace{n_{\text{SV}}}_{\text{vectores de soporte}}$$

SVR con Kernel RBF

Configurado inicialmente con $C = 1,0$, $\varepsilon = 0,1$ y $\gamma = 0,1$. Este modelo combina la flexibilidad del kernel RBF con la función de pérdida ε -insensible. El parámetro γ controla la no-linealidad de la proyección hacia el espacio de características, permitiendo capturar dependencias complejas entre los indicadores. La optimización simultánea de estos tres hiperparámetros regula la topología del espacio de predicción y, en última instancia, el número de vectores de soporte seleccionados, que determina la complejidad final del modelo:

$$n_{\text{params}} = \underbrace{3}_{\{C, \varepsilon, \gamma\}} + \underbrace{n_{\text{SV}}}_{\text{vectores de soporte}}$$

8. Selección de Hiperparámetros con Validación Cruzada

8.1. Motivación

En sistemas altamente estocásticos y ruidosos como el mercado bursátil, los algoritmos con alta capacidad matemática son extremadamente propensos a memorizar las trayectorias pasadas, creando una peligrosa ilusión de precisión conocida como sobreajuste. Por ello, se busca hacer uso de validación cruzada (adaptada para series de tiempo) y así garantizar que los hiperparámetros seleccionados confieren una genuina capacidad de generalización. Al someter a los modelos a continuas evaluaciones sobre subconjuntos de datos no vistos, sin violar la causalidad temporal, esta técnica asegura que el rendimiento final del modelo refleje una verdadera asimilación de las dinámicas subyacentes de las acciones, y no una simple memorización de sus anomalías históricas.

8.2. Validación cruzada temporal

Un k-fold ordinario en series de tiempo provoca que datos del futuro aparezcan en el entrenamiento de un fold y datos del pasado en la validación, lo cual es irreal e invalida la evaluación. Por otro lado, `TimeSeriesSplit` respeta el orden temporal, donde cada fold extiende el entrenamiento y valida en datos más recientes:

Fold	Entrenamiento	Validación
1	$[1, n_1]$	$[n_1 + 1, n_2]$
2	$[1, n_2]$	$[n_2 + 1, n_3]$
3	$[1, n_3]$	$[n_3 + 1, n_4]$
4	$[1, n_4]$	$[n_4 + 1, n_5]$
5	$[1, n_5]$	$[n_5 + 1, n_6]$

Se usan $K = 5$ folds. Para cada combinación de hiperparámetros se calcula el RMSE promedio en los 5 folds de validación, y se selecciona la combinación con menor RMSE promedio.

8.3. Grillas de búsqueda

Debido a que la sensibilidad de las funciones de pérdida respecto a sus parámetros suele seguir una distribución exponencial, las grillas se estructuraron utilizando una escala geométrica (saltos logarítmicos). Esto garantiza una exploración exhaustiva del espacio de configuraciones abarcando distintos órdenes de magnitud, desde modelos altamente restringidos hasta modelos con extrema flexibilidad empírica.

■ **Ridge Lineal:** 35 entrenamientos

$$\alpha \in \{0,001, 0,01, 0,1, 1, 10, 100, 1000\}$$

El parámetro α controla la severidad de la penalización L_2 impuesta sobre la norma de los pesos vectoriales ($\|\mathbf{w}\|^2$). Valores cercanos a 0,001 permiten que el modelo se comporte de manera muy similar a una regresión lineal ordinaria por mínimos cuadrados, por otro lado, valores más altos causan una fuerte contracción espacial de los coeficientes para mitigar la colinealidad intrínseca de los indicadores técnicos financieros.

■ **Ridge con Kernel RBF:** 120 entrenamientos

$$\alpha \in \{0,001, \dots, 100\}, \quad \gamma \in \{0,001, 0,01, 0,1, 1\}$$

El hiperparámetro γ define explícitamente el inverso del radio de influencia de cada muestra de entrenamiento. Valores de $\gamma = 0,001$ implican una influencia global y suave (comportamiento casi lineal), mientras que $\gamma = 1$ restringe la influencia de manera local, lo que permite trazar fronteras de predicción altamente complejas y rugosas.

■ **SVR Lineal:** 125 entrenamientos

$$C \in \{0,01, 0,1, 1, 10, 100\}, \quad \varepsilon \in \{0,01, 0,05, 0,1, 0,5, 1\}$$

El parámetro C establece un límite estricto superior sobre las variables de holgura. Valores bajos ($C = 0,01$) priorizan la maximización del margen geométrico (modelos robustos a valores atípicos del mercado accionario), mientras que valores elevados ($C = 100$) penalizan severamente cualquier desviación fuera del margen. Por su parte, el parámetro ε dicta el ancho del tubo ε -insensible, actuando como un filtro de ruido estocástico; un ε demasiado grande colapsa la predicción hacia la media de la serie.

■ **SVR con Kernel RBF:** 240 entrenamientos

$$C \in \{0,1, 1, 10, 100\}, \quad \varepsilon \in \{0,01, 0,1, 0,5\}, \quad \gamma \in \{0,001, 0,01, 0,1, 1\}$$

La interacción de estos tres hiperparámetros determina simultáneamente el ancho del tubo tolerado al error, la penalización por violar dicho margen y la dimensión topológica de las proyecciones no lineales.

9. Resultados de los Modelos

Todos los modelos se entrenaron sobre los 1,105 días más antiguos y se evaluaron sobre los 474 días más recientes, respetando la naturaleza secuencial de la serie temporal.

9.1. Precisión Predictiva: RMSE y MAPE

Las Tablas 2 y 3 reportan el error de predicción de cada modelo sobre el conjunto de prueba. El mapa de calor de la Figura 1 permite identificar visualmente los patrones de error tanto por modelo como por acción, facilitando la detección de casos atípicos.

Cuadro 2: RMSE en el conjunto de prueba (474 días) para cada acción y modelo. La columna *Promedio* corresponde a la media aritmética de las seis acciones.

Modelo	AVGO	CSCO	DELL	GOOGL	HPE	MU	Promedio
Random Walk	8.28	1.05	4.07	4.38	0.54	8.71	4.51
Ridge Lineal con VC	11.35	1.39	5.42	5.69	0.70	12.07	6.10
SVR Lineal con VC	12.92	1.37	6.42	6.23	0.71	14.01	6.94
Ridge Lineal	13.68	1.60	6.37	6.72	0.80	15.34	7.42
SVR Lineal	14.43	1.54	7.22	7.03	0.80	16.74	7.96
Ridge con Kernel RBF y VC	36.99	1.94	6.17	24.66	0.79	63.10	22.28
SVR con Kernel RBF y VC	135.19	6.42	7.59	50.21	1.72	138.96	56.68
SVR con Kernel RBF	162.95	7.78	56.38	75.40	2.07	147.00	75.26
Ridge con Kernel RBF	169.34	14.23	11.69	82.68	3.51	174.58	76.01

Cuadro 3: MAPE (%) en el conjunto de prueba para cada acción y modelo.

Modelo	AVGO	CSCO	DELL	GOOGL	HPE	MU	Promedio
Random Walk	2.30	1.04	2.37	1.41	1.87	2.95	1.99
Ridge Lineal con VC	3.29	1.50	3.26	1.85	2.58	4.10	2.76
SVR Lineal con VC	3.77	1.48	3.95	1.98	2.61	4.62	3.07
Ridge Lineal	4.06	1.75	3.84	2.13	2.99	4.95	3.29
SVR Lineal	4.36	1.67	4.48	2.25	2.97	5.33	3.51
Ridge con Kernel RBF y VC	9.14	2.01	3.53	5.15	2.95	9.79	5.43
SVR con Kernel RBF y VC	33.43	5.85	3.78	10.33	5.86	21.36	13.43
SVR con Kernel RBF	48.01	7.56	42.06	21.85	7.21	28.58	25.88
Ridge con Kernel RBF	43.61	14.19	6.13	18.96	12.84	28.01	20.62




Figura 1: Mapas de calor de RMSE y MAPE por acción y modelo. Las celdas más oscuras indican mayor error. Se aprecia con claridad la brecha entre los modelos lineales (filas superiores, tonos claros) y los modelos con kernel RBF sin validación cruzada (filas inferiores, tonos rojos intensos).

9.2. Ranking Global de Modelos

Se puede observar que *Random Walk* encabeza el ranking con un RMSE promedio de **4.51 USD**, lo que revela que ningún modelo de aprendizaje automático logra superar su predicción trivial. Entre los modelos supervisados, **Ridge Lineal con validación cruzada** obtiene el menor error, seguido por el SVR Lineal con validación cruzada. En el extremo opuesto, los modelos con kernel RBF sin optimización alcanzan errores casi **17 veces** superiores al *Random Walk*.




Figura 2: Ranking de modelos según RMSE promedio sobre las seis acciones. La brecha entre los modelos lineales ($RMSE < 9$) y los modelos con kernel RBF ($RMSE > 22$) es evidente, independientemente de si se aplica validación cruzada.

9.3. Comportamiento por Acción

La Figura 3 desglosa el RMSE de cada modelo para las seis acciones de forma individual.

Las emisoras de mayor precio absoluto (AVGO, entre 800 y 1,800 USD; MU, entre 60 y 100 USD) registran los RMSE más altos en términos absolutos, lo cual es esperable dado que el RMSE se expresa en las mismas unidades que el precio. Sin embargo, incluso el MAPE muestra diferencias persistentes: CSCO presenta el MAPE más bajo en casi todos los modelos ($\approx 1,5\%$), mientras que MU y AVGO alcanzan valores de hasta 5 % en los modelos lineales, reflejando que la predecibilidad no es uniforme y está estrechamente asociada a la volatilidad intrínseca de cada activo (véase el Cuadro 1).

Por otro lado, el colapso del kernel RBF sin validación cruzada es especialmente pronunciado en las acciones de mayor precio. Se puede evidenciar un sobreajuste severo al memorizar la escala de precios histórica sin capacidad de generalización.




Figura 3: RMSE por acción para cada modelo evaluado. Las líneas del *Random Walk* (gris punteado) y de los modelos lineales permanecen agrupadas y cercanas a la base, mientras que los modelos con kernel RBF sin validación cruzada presentan divergencias extremas en AVGO, GOOGL y MU.

10. Impacto de la Validación Cruzada y Análisis de Complejidad

Esta sección examina dos preguntas centrales del experimento: ¿cuánto mejora el desempeño al optimizar sus hiperparámetros mediante validación cruzada?, y ¿existe una relación entre la complejidad estructural de un modelo y su capacidad predictiva en este dominio?

10.1. Efecto de la Validación Cruzada sobre el RMSE

Cuadro 4: Reducción de RMSE promedio (sobre seis acciones) producida por la validación cruzada en cada familia de modelos. La columna *Reducción* corresponde a $(\text{RMSE}_{\text{sin VC}} - \text{RMSE}_{\text{con VC}}) / \text{RMSE}_{\text{sin VC}} \times 100 \%$.

Modelo	RMSE sin VC	RMSE con VC	Reducción (%)
Ridge Lineal	7.42	6.10	17.7 %
SVR Lineal	7.96	6.94	12.8 %
Ridge con RBF	76.01	22.28	70.7 %
SVR con RBF	75.26	56.68	24.7 %




Figura 4: Impacto de la validación cruzada sobre el RMSE promedio por familia de modelos.

Modelos lineales

En ambas variantes lineales, la validación cruzada produce reducciones moderadas pero consistentes: 17.7 % para el Ridge y 12.8 % para el SVR lineal (Tabla 4). Este

comportamiento refleja que los modelos lineales poseen un espacio de hiperparámetros relativamente reducido y una función de pérdida convexa que limita el riesgo de sobreajuste.

La mejora introducida por la validación cruzada en estos modelos proviene principalmente de la identificación de la intensidad de regularización óptima.

Ridge con kernel RBF

El RMSE promedio cae de 76.01 a 22.28, una reducción del 70.7%. Sin embargo, aun con hiperparámetros optimizados, este modelo triplica el error del Ridge lineal sin validación cruzada. El problema estructural de fondo es la alta varianza inherente al kernel RBF ante la combinación de un espacio de características de alta dimensión (1,107 parámetros efectivos).

SVR con kernel RBF

Reduce su RMSE en un 24.7 % respecto a la versión sin optimización, pero el nivel absoluto sigue siendo elevado (RMSE = 56,68 en promedio). Esta resistencia a mejorar sugiere que el kernel RBF posee alta sensibilidad con γ : pequeñas variaciones en este parámetro pueden llevar al modelo a memorizar el conjunto de entrenamiento o a producir una función de predicción casi constante.

10.2. Complejidad Estructural contra Desempeño Predictivo

La Tabla 5 y la Figura 5 presentan una comparación integrada de todos los modelos, ordenados por RMSE ascendente e incluyendo el número de parámetros ajustados como medida de complejidad estructural.

Cuadro 5: Complejidad estructural y desempeño predictivo de todos los modelos evaluados, ordenados por RMSE promedio ascendente.

Modelo	Parámetros	RMSE prom.	MAPE prom. (%)
Random Walk	0	4.51	1.99
Ridge Lineal con VC	7	6.10	2.76
SVR Lineal con VC	946	6.94	3.07
Ridge Lineal	7	7.42	3.29
SVR Lineal	1,005	7.96	3.51
Ridge con Kernel RBF y VC	1,107	22.28	5.43
SVR con Kernel RBF y VC	899	56.68	13.43
SVR con Kernel RBF	1,035	75.26	25.88
Ridge con Kernel RBF	1,107	76.01	20.62




Figura 5: Relación entre la complejidad del modelo (número de parámetros ajustados) y el RMSE promedio. La línea punteada gris indica el umbral del *Random Walk* (RMSE = 4,51).

10.3. Conclusión: Desempeño, Validación Cruzada y Complejidad

Los resultados revelan una relación **inversa** entre la complejidad estructural del modelo y su capacidad de generalización en este problema. El mejor modelo supervisado es el **Ridge Lineal con validación cruzada**, que ajusta únicamente **7 parámetros**. En el extremo opuesto, los modelos con kernel RBF (que ajustan más de **1,000 parámetros**) ocupan los últimos lugares del ranking, incluso después de la optimización de hiperparámetros.

La comparación directa entre los dos mejores modelos supervisados ilustra este principio con claridad:

Modelo	Parámetros	RMSE prom.	MAPE prom.
Ridge Lineal con VC	7	6.10	2.76 %
SVR Lineal con VC	946	6.94	3.07 %
<i>Factor de complejidad</i>			$\approx 135\times$

El Ridge Lineal con VC supera al SVR Lineal con VC en ambas métricas con una complejidad aproximadamente **135 veces menor**. En este escenario, la regularización L_2 del Ridge (que contrae los coeficientes de forma continua y analíticamente tratable) resulta más adecuada que la estructura de vectores de soporte del SVR, cuya función

de pérdida ε -insensible introduce un sesgo adicional en acciones de alta volatilidad como AVGO y MU, donde la mayoría de los errores diarios ya exceden el umbral ε y el beneficio del tubo se diluye.

Respecto a la validación cruzada, los resultados permiten establecer dos conclusiones complementarias. Por un lado, es indispensable para los modelos con kernel RBF, pues la validación cruzada reduce sus errores sustancialmente, aunque sin lograr que sean competitivos frente a los modelos lineales. Por otro lado, en los modelos lineales la validación cruzada produce mejoras confiables y consistentes al identificar la intensidad de regularización óptima, colocando al Ridge Lineal con VC como el mejor balance entre capacidad predictiva, interpretabilidad y eficiencia computacional dentro del conjunto evaluado.

En síntesis, cuando la señal predictiva es débil y el ruido domina la serie (como ocurre en los mercados financieros), la complejidad adicional modela el ruido en lugar de la señal.

11. Estrategia de Ventana Deslizante

11.1. Motivación

El experimento estático descrito en la sección anterior entrena cada modelo una sola vez sobre el 70 % de los datos más antiguos y evalúa sobre el 30 % restante sin ninguna actualización posterior. Esta estrategia ignora un rasgo fundamental de los mercados financieros: las condiciones de volatilidad, tendencia y correlación entre indicadores no son estacionarias, sino que evolucionan con el tiempo.

Para abordar esta limitación, Henrique et al. (2018) proponen complementar el análisis estático con una estrategia de **ventana deslizante** (*moving training window*), en la que el modelo se reentrena periódicamente a medida que llegan nuevos datos, restringiendo su memoria a un horizonte temporal reciente y fijo.

11.2. Formulación Matemática

Sea $\mathcal{W}_t$ el conjunto de los W días inmediatamente anteriores al día de prueba t :

$$\mathcal{W}_t = \{(\mathbf{x}_i, y_i)\}_{i=t-W}^{t-1} \quad (29)$$

Para cada día t del conjunto de prueba, el procedimiento consiste en: entrenar el modelo sobre $\mathcal{W}_t$ con los hiperparámetros óptimos obtenidos previamente por validación cruzada; generar la predicción $\hat{y}_t$ para el día t ; evaluar el error y desplazar la ventana un día hacia adelante.

Este proceso se repite para cada uno de los 474 días del conjunto de prueba, produciendo una secuencia de predicciones adaptativas.

11.3. Decisiones de Implementación

La implementación de la ventana deslizante involucra tres decisiones metodológicas que se detallan a continuación.

Tamaño de ventana $W = 60$ días

Se seleccionó una ventana de 60 días de mercado, equivalente a aproximadamente tres meses de cotización. Esto con el fin de que el modelo disponga de una muestra estadísticamente representativa al momento del reentrenamiento y también capture las dinámicas recientes del mercado sin verse contaminado por patrones obsoletos.

Hiperparámetros fijos

Los valores óptimos encontrados por validación cruzada en el experimento estático se reutilizan en cada reentrenamiento bajo el supuesto de que son relativamente estables a lo largo del período de prueba. Ejecutar una búsqueda en cuadrícula completa por cada uno de los 474 pasos temporales elevaría el costo computacional en varios órdenes de magnitud.

Normalización

El `MinMaxScaler` se ajusta una sola vez sobre el conjunto de entrenamiento original y se aplica de manera uniforme a toda la serie temporal. Esta decisión evita la filtración de información futura (*data leakage*) que ocurriría si el normalizador se reajustara en cada ventana.

11.4. Resultados de los Modelos con Ventana Deslizante

Se aplican las cuatro familias de modelos con sus hiperparámetros óptimos. Las Tablas 6 y 7 presentan los errores de predicción obtenidos con la estrategia de ventana deslizante. La Figura 6 contrasta estos resultados con los del experimento estático, cuantificando la ganancia o pérdida de precisión que introduce el reentrenamiento dinámico.

Cuadro 6: RMSE por acción y modelo con ventana deslizante ($W = 60$ días).

Modelo	AVGO	CSCO	DELL	GOOGL	HPE	MU	Promedio
Ridge Lineal VD	11.51	1.40	5.43	5.78	0.72	12.62	6.24
Ridge RBF VD	11.70	1.43	5.61	5.67	0.76	11.92	6.18
SVR Lineal VD	12.35	1.44	6.18	6.22	0.76	14.18	6.85
SVR RBF VD	14.28	1.46	8.07	7.58	0.77	14.23	7.73

Cuadro 7: MAPE (%) por acción y modelo con ventana deslizante ($W = 60$ días).

Modelo	AVGO	CSCO	DELL	GOOGL	HPE	MU	Promedio
Ridge Lineal VD	3.48	1.56	3.34	1.95	2.72	4.16	2.87
Ridge RBF VD	3.54	1.63	3.47	1.92	2.91	4.21	2.95
SVR Lineal VD	3.64	1.58	3.90	2.09	2.83	4.59	3.10
SVR RBF VD	4.19	1.64	5.33	2.67	2.88	4.91	3.60




Figura 6: Comparación del RMSE promedio entre los modelos estáticos con validación cruzada y sus equivalentes con ventana deslizante ($W = 60$ días). El porcentaje indica la variación del error al pasar del esquema estático al dinámico.

11.5. Análisis de Resultados

Corrección del sobreajuste en los modelos con kernel RBF

El hallazgo más relevante de la ventana deslizante es la corrección sustancial del sobreajuste en los modelos basados en el kernel RBF. Al restringir la memoria del modelo a los 60 días de cotización más recientes, se impide que el kernel mapee anomalías y tendencias obsoletas, forzando una adaptación continua a las correlaciones vigentes entre los indicadores técnicos y el precio de cierre.

Un resultado particularmente llamativo es que el **Ridge RBF VD** ($RMSE = 6,18$) alcanza un desempeño prácticamente equivalente al del Ridge Lineal con VC en el esquema estático ($RMSE = 6,10$), revirtiendo por completo la brecha que separaba ambas familias de modelos. Esto sugiere que, con un horizonte de entrenamiento adecuado, el kernel RBF puede capturar relaciones no lineales locales entre los indicadores y el precio que el kernel lineal no detecta.

Estabilidad de los modelos lineales

En contraste, los modelos lineales mostraron una respuesta inelástica a la ventana deslizante. Esta estabilidad refleja el balance intrínseco del reentrenamiento periódico sobre modelos de baja capacidad, por lo que el desempeño de los modelos lineales está estructuralmente acotado por su propia simplicidad geométrica, independientemente de la cantidad de datos disponibles para el entrenamiento.

Costo computacional

La ganancia en adaptabilidad conlleva un costo computacional proporcional. El esquema dinámico requiere 474 reentrenamientos por modelo por acción, lo que equivale a un total de 11,376 ajustes para el ensamble completo. Una reoptimización completa en cada paso temporal haría computacionalmente inviable el sistema para aplicaciones de análisis en tiempo real, sin garantía de una mejora proporcional en la precisión.

12. Conclusiones

El presente proyecto evaluó la capacidad predictiva del modelo de *Support Vector Regression* (SVR) para el precio de cierre diario de seis activos del mercado accionario estadounidense, contrastándolo contra la Regresión Ridge, la Caminata Aleatoria y distintas configuraciones de kernel. Los resultados obtenidos permiten establecer las siguientes conclusiones.

Sobre la dificultad intrínseca del problema

Ningún modelo supervisado logró superar a la Caminata Aleatoria. Esto es consistente con la Hipótesis de los Mercados Eficientes (EMH). En consecuencia, los indicadores SMA, WMA, RSI, ADO y ATR, calculados con una ventana de $P = 10$ días, no capturan de forma suficiente la señal predictiva necesaria para superar este umbral de referencia.

Sobre la elección de kernel

La comparación entre kernels revela una brecha estructural clara e independiente de la familia de modelos. Los modelos lineales (Ridge Lineal y SVR Lineal) mantuvieron un RMSE promedio menor a 8 USD en el experimento estático, mientras que los modelos con kernel RBF sin optimización alcanzaron errores de hasta 76 USD, es decir, casi 17 veces superiores al *Random Walk*. Esta divergencia evidencia que el kernel RBF, al proyectar los datos a un espacio de características de alta dimensión, memoriza las trayectorias históricas de precios en lugar de capturar dinámicas generalizables. Dado que la señal predictiva es débil y el ruido domina las series financieras, la capacidad expresiva adicional del kernel RBF se convierte en una fuente de sobreajuste severo, en lugar de una ventaja. Se concluye que, en este dominio, la complejidad adicional modela el ruido y no la señal.

Sobre la validación cruzada temporal

La validación cruzada temporal demostró ser una herramienta indispensable, cuyo impacto varía considerablemente según la familia de modelo. Para los modelos lineales, la optimización de hiperparámetros produjo reducciones moderadas y consistentes. Para los modelos con kernel RBF, el impacto fue mayor. No obstante, incluso tras la optimización, estos modelos no lograron ser competitivos frente a sus contrapartes lineales. La validación cruzada resulta por tanto necesaria pero no suficiente para corregir las deficiencias estructurales del kernel RBF en este contexto.

Sobre la complejidad estructural y la generalización

Los resultados evidencian una relación inversa entre la complejidad estructural del modelo y su capacidad de generalización. El mejor modelo supervisado, el Ridge Lineal con validación cruzada ajusta únicamente 7 parámetros. En contraste, el SVR Lineal con validación cruzada, que ajusta 946 parámetros, es superado por el Ridge con una complejidad aproximadamente 135 veces menor. Este resultado indica que en dominios de alta estocasticidad, la penalización continua y analíticamente tratable de la norma L_2 del Ridge resulta más adecuada que la función de pérdida ε -insensible del SVR, cuyo beneficio se diluye cuando la mayoría de los errores diarios ya exceden el umbral ε .

Sobre la ventana deslizante


La estrategia de ventana deslizante ($W = 60$ días) introdujo resultados asimétricos según la familia de modelos. Para los modelos lineales, el reentrenamiento dinámico produjo variaciones marginales en el RMSE, confirmando que su desempeño está estructuralmente acotado por su propia simplicidad geométrica. El hallazgo más relevante se observó en el Ridge RBF con ventana deslizante), que alcanzó un desempeño prácticamente equivalente al del mejor modelo estático (Ridge Lineal con VC). Esto sugiere que, cuando el kernel RBF se restringe a un horizonte de entrenamiento reciente y localizado, puede capturar relaciones no lineales vigentes entre los indicadores técnicos y el precio que el kernel lineal no detecta. Sin embargo, esta adaptabilidad conlleva un costo computacional de 474 reentrenamientos por modelo por acción.

Reflexión final



En síntesis, los resultados de este proyecto demuestran que la predicción del precio de cierre diario mediante indicadores técnicos es un problema dominado por el ruido estocástico, en el que los modelos más simples y regularizados generalizan mejor que los modelos de alta capacidad. El SVR, a pesar de sus propiedades teóricas favorables, no demostró ventajas prácticas sobre la Regresión Ridge en el esquema estático. No obstante, la ventana deslizante sugiere que su variante con kernel RBF podría ser competitiva en un esquema de reentrenamiento adaptativo, abriendo una línea de trabajo futura que combine la flexibilidad no lineal del kernel con horizontes de entrenamiento dinámicos y técnicas de selección de características más robustas al ruido financiero.

12. Visualización de Gráficos



Como ayuda visual de los resultados del entrenamiento de los modelos, se presentan los gráficos en el conjunto de prueba para las acciones evaluadas, considerando la optimización de hiperparámetros.





Predicciones vs Precio Real — DELL (últimos 100 días del conjunto de prueba)





Predicciones vs Precio Real — GOOGL (últimos 100 días del conjunto de prueba)



Predicciones vs Precio Real — HPE (últimos 100 días del conjunto de prueba)



Predicciones vs Precio Real — MU (últimos 100 días del conjunto de prueba)



Referencias

- [1] Henrique, B. M., Sobreiro, V. A., & Kimura, H. (2018). *Stock price prediction using support vector regression on daily and up to the minute prices*. The Journal of Finance and Data Science, 4(4), 183–201. <https://doi.org/10.1016/j.jfds.2018.04.003>
- [2] Vapnik, V. N. (1995). *The Nature of Statistical Learning Theory*. Springer, New York.
- [3] Malkiel, B. G., & Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383–417.
- [4] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://scikit-learn.org>